

Diseño inverso de metamateriales spinodoidales: comparación de subrogados y caracterización de la degeneración angular

Vicente José Allendes Galleguillos

Escuela de Ingeniería Civil Biomédica

Facultad de Ingeniería, Universidad de Valparaíso, Chile

Resumen

El diseño inverso de metamateriales spinodoidales es un problema mal condicionado por su no-unicidad y costoso computacionalmente. Sobre 10 011 muestras, se comparan tres modelos de mapeo directo (f -NN, f -NN-prob y GP), superando todos $R^2 > 0,985$, con el GP ofreciendo la mejor calibración ($ECE = 2,8 \times 10^{-3}$). El *temperature scaling* ($s^* = 0,425$) ajusta la cobertura de f -NN-prob del 84,2 % al 65,8 % para un intervalo nominal del 68 %. En extrapolación, la incertidumbre del GP se multiplica por 3,47, mientras que la red la reduce a 0,75. Para el mapeo inverso (i -NN, ensamble y MDN con $K = 1, 3$), el análisis de importancia revela que β y ρ concentran > 99 % de la influencia sobre G , siendo los ángulos de anisotropía irrelevantes. Entre el 16 % y 22 % del espacio paramétrico reproduce cada geometría, con una dispersión angular de 26° consistente con una distribución uniforme. La comparación $K = 1$ vs $K = 3$ muestra una degeneración continua, no discreta. Se concluye que la no identificabilidad angular es inherente a la representación escalar de G , y que la solución requiere modelar la distribución condicional completa y validar físicamente mediante el mapeo directo.

Palabras Clave: metamateriales spinodoidales, diseño inverso, modelo subrogado, procesos gaussianos, redes de densidad mixta, cuantificación de incertidumbre.

1 INTRODUCCIÓN

Los metamateriales spinodoidales son microestructuras estocásticas con propiedades sintonizables a través de pocos parámetros de diseño. Su simulación es costosa: requiere generar campos aleatorios gaussianos anisótropos, construir isosuperficies y mallar volúmenes para extraer descriptores geométricos, a razón de unos 133 segundos por muestra en el equipo utilizado. Ese costo limita la cantidad de datos disponibles y hace inviable explorar el espacio de diseño por fuerza bruta.

Este trabajo desarrolla modelos subrogados que aproximan el mapeo entre parámetros de diseño $\Theta = (\beta, \rho, \theta_1, \theta_2, \theta_3)$ y propiedades geométricas G , siguiendo el esquema de dos redes de Kumar *et al.* [1]. Los objetivos son: (i) implementar el subrogado directo y la red inversa; (ii) comparar una red

determinista, una con verosimilitud explícita y un GP, caracterizando además la eficiencia de datos del mapeo directo; (iii) caracterizar y recalibrar la incertidumbre predictiva, evaluando además su comportamiento fuera del dominio de entrenamiento; (iv) diagnosticar la no-unicidad del problema inverso mediante Monte Carlo, ensamble y redes de densidad mixta, verificando la generalidad del diagnóstico sobre múltiples muestras y su robustez ante el umbral de compatibilidad.

La contribución principal de este trabajo consiste en demostrar experimentalmente que la degeneración angular del diseño inverso spinodoidal no corresponde a un conjunto de modos discretos, sino a una degeneración continua inducida por la representación escalar de G : cuatro estimaciones independientes convergen a una dispersión angular de 26° , y las soluciones alternativas se validan mediante consistencia con el mapeo directo.

2 MARCO TEÓRICO

2.1 Redes feedforward y verosimilitud

Una red feedforward compone transformaciones afines y activaciones no lineales (ReLU en este trabajo), $f(x; \phi)$, con parámetros ϕ . Bajo el supuesto $y_i = f(x_i; \phi) + \varepsilon_i$ con ruido gaussiano homocedástico, minimizar el MSE equivale a estimación de máxima verosimilitud. Si además la red predice la varianza condicional $\sigma^2(x)$, la log-verosimilitud negativa por muestra se vuelve heterocedástica:

$$\ell = \sum_j \left[\frac{1}{2} s_j(x) + \frac{1}{2} (y_j - \mu_j(x))^2 e^{-s_j(x)} \right], \quad (1)$$

donde $s_j = \log \sigma_j^2$ garantiza positividad y se asume independencia condicional entre salidas. El primer término penaliza inflar la varianza; el segundo pondera el error por la precisión declarada. El mínimo se alcanza cuando σ_j^2 iguala al error cuadrático esperado.

2.2 Descomposición sesgo-varianza

Para M modelos $\{\hat{y}_m\}$ entrenados con distintas semillas, con promedio $\bar{y}$, el error respecto de un objetivo y^* se des-

compone como

$$\underbrace{\frac{1}{M} \sum_m (\hat{y}_m - y^*)^2}_{\text{Error}} = \underbrace{(\bar{y} - y^*)^2}_{\text{Sesgo}^2} + \underbrace{\frac{1}{M} \sum_m (\hat{y}_m - \bar{y})^2}_{\text{Varianza}}. \quad (2)$$

2.3 Procesos gaussianos

Un GP define una distribución sobre funciones, $f \sim \mathcal{GP}(m, k)$, con núcleo de covarianza k . Dado el conjunto de entrenamiento con ruido σ_n^2 , la predicción posterior en x_* es gaussiana:

$$\mu_* = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}, \quad \sigma_*^2 = k(x_*, x_*) - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{k}_*. \quad (3)$$

La varianza posterior parte del máximo $k(x_*, x_*)$ y se reduce en la medida en que los datos de entrenamiento sean informativos sobre x_* ; crece automáticamente en regiones poco muestreadas. Con un núcleo RBF de longitudes de escala por dimensión (ARD), las longitudes optimizadas ℓ_j actúan como medida de relevancia: ℓ_j grande implica que la salida varía poco con la entrada j .

2.4 Calibración y recalibración de la incertidumbre

Un modelo probabilístico está calibrado en segundo momento si su varianza declarada coincide con el error cuadrático empírico. Agrupando el test en quintiles de σ^2 predicho, el *Expected Calibration Error* (ECE) promedia la discrepancia $|\mathbb{E}[\sigma^2] - \text{MSE}|$ ponderada por el tamaño de cada bin. Cuando el modelo está mal calibrado por un factor sistemático, la corrección natural es un *temperature scaling* adaptado a regresión: se busca s tal que $\sigma_{\text{cal}}^2 = s \sigma^2$ minimice la NLL en validación. Derivando la NLL gaussiana respecto de s e igualando a cero,

$$\frac{\partial}{\partial s} \left[\frac{1}{2} \log(s \sigma_i^2) + \frac{(y_i - \mu_i)^2}{2s \sigma_i^2} \right] = 0 \Rightarrow s^* = \frac{\overline{(y - \mu)^2}}{\sigma^2}, \quad (4)$$

es decir, el factor óptimo es el ratio promedio entre error real y varianza declarada. La media μ no se altera, por lo que el R^2 permanece idéntico.

2.5 Problema inverso, no-unicidad y MDN

Cuando varios Θ producen la misma G , la condicional $p(\Theta | G)$ deja de ser una función y el óptimo bajo MSE es $\mathbb{E}[\Theta | G]$, el promedio de las soluciones, que en general no es una solución válida. Una red de densidad mixta [2] evita el colapso modelando la condicional completa como la mezcla de la Ecuación (5):

$$p(\Theta | G) = \sum_{k=1}^K \pi_k(G) \mathcal{N}(\Theta | \mu_k(G), \text{diag}(\sigma_k^2(G))), \quad (5)$$

donde una única red predice pesos π_k (softmax), medias μ_k y log-varianzas s_k . La pérdida es la NLL de la mezcla,

$$\mathcal{L} = -\log \sum_k \exp \left[\log \pi_k + \sum_j \left(-\frac{1}{2} s_{kj} - \frac{1}{2} (\theta_j - \mu_{kj})^2 e^{-s_{kj}} \right) \right] + C, \quad (6)$$

2.6 Estrategia de reconstrucción

La red inversa se entrena sin etiquetas únicas con la pérdida de reconstrucción de [1],

$$\mathcal{L}_{\text{rec}}(\psi) = \|f(g(G; \psi); \hat{\phi}) - G\|^2 + \lambda \|g(G; \psi) - \Theta\|^2, \quad (7)$$

con $\hat{\phi}$ los pesos congelados de la f-NN.

3 ESTADO DEL ARTE

Los problemas inversos mal planteados en el sentido de Hadamard violan existencia, unicidad o estabilidad, y son transversales desde las imágenes médicas hasta la aerodinámica [11]. Haltmeier y Nguyen [9] demuestran que todo método de reconstrucción basado en datos regulariza, explícita o implícitamente: el minimizador de MSE sobre una condicional degenerada no es una solución, sino una regularización implícita hacia la media condicional. Mills *et al.* [10] lo verifican en inversión geofísica: con posterior multimodal, la media del ensamble es un mal predictor de los datos, y resultan mejores representantes la mediana en espacio de datos o el clustering. Guilhoto *et al.* [12] muestran que en régimen de pocos datos las MDN superan a los modelos de difusión y *flows*, reduciendo la discrepancia MMD 27 veces respecto de la regresión MSE en el sistema de Lorenz. Estos resultados fundamentan, respectivamente, el diagnóstico teórico, el rechazo del promedio y la elección de la MDN en este trabajo.

En el dominio específico, Kumar *et al.* [1] introducen las topologías spinodoidales y el esquema de dos redes (19,170 pares de entrenamiento): su pérdida de reconstrucción reproduce el tensor elástico objetivo seleccionando una solución válida, sin caracterizar el conjunto. La literatura posterior ataca el costo de datos: Rosenkranz *et al.* [3] bajan a 75 muestras codificando las simetrías del problema en la arquitectura (errores del 0,2 al 3,3 % en diseño inverso); Danesh *et al.* [5] igualan con el 0,61 % de los datos el MAE del dataset completo mediante GP con aprendizaje activo; Danesh y Wessels [6] superan el 96 % de éxito en 7,000 tareas inversas etiquetando el 0,4 % de 50,000 candidatos; y Raßloff *et al.* [8] ajustan los módulos de Young de hueso trabecular real con desviación del 0,040 % desde 16 pares iniciales, señalando que las ambigüedades rotacionales no impiden la convergencia, sin estudiarlas. He y Ren [7] demuestran el carácter uno-a-muchos del problema y lo sortean con inferencia bayesiana en el latente de un autoencoder variacional ($R^2 > 96$ % multipropiedad). A mayor escala, TEGNet [4] emula generadores termoeléctricos con precisión mayor al 99 % en el 0,01 % del tiempo de elementos finitos.

En síntesis, los trabajos previos resuelven el diseño inverso con muy pocos datos, pero tratan la no-unicidad como un obstáculo: Raßloff *et al.* la mencionan sin medirla y He y Ren la ilustran sin caracterizarla. Ninguno estudia empíricamente su estructura: si es discreta o continua, qué dimensión tiene y de qué representación depende. Ese es el vacío que este trabajo aborda, mediante una comparación controlada de tres subrogados en régimen de datos limitados, un tratamiento completo de la incertidumbre y una caracterización empírica de la degeneración con tres herramientas complementarias, replicada sobre múltiples muestras y verificada ante variaciones del umbral.

4 ESTADO DEL ARTE

Los problemas inversos mal planteados en el sentido de Hadamard violan existencia, unicidad o estabilidad, y son transversales desde las imágenes médicas hasta la aerodinámica [11]. Haltmeier y Nguyen [9] demuestran que todo método de reconstrucción basado en datos regulariza, explícita o implícitamente: el minimizador de MSE sobre una condicional degenerada no es una solución, sino una regularización implícita hacia la media condicional. Mills *et al.* [10] lo verifican en inversión geofísica: con posterior multimodal, la media del ensamble es un mal predictor de los datos, y resultan mejores representantes la mediana en espacio de datos o el clustering. Guilhoto *et al.* [12] muestran que en régimen de pocos datos las MDN superan a los modelos de difusión y *flows*, reduciendo la discrepancia MMD 27 veces respecto de la regresión MSE en el sistema de Lorenz. Estos resultados fundamentan, respectivamente, el diagnóstico teórico, el rechazo del promedio y la elección de la MDN en este trabajo.

En el dominio específico, Kumar *et al.* [1] introducen las topologías spinodoidales y el esquema de dos redes (19,170 pares de entrenamiento): su pérdida de reconstrucción reproduce el tensor elástico objetivo seleccionando una solución válida, sin caracterizar el conjunto. La literatura posterior ataca el costo de datos: Rosenkranz *et al.* [3] bajan a 75 muestras codificando las simetrías del problema en la arquitectura (errores del 0,2 al 3,3 % en diseño inverso); Danesh *et al.* [5] igualan con el 0,61 % de los datos el MAE del dataset completo mediante GP con aprendizaje activo; Danesh y Wessels [6] superan el 96 % de éxito en 7,000 tareas inversas etiquetando el 0,4 % de 50,000 candidatos; y Raßloff *et al.* [8] ajustan los módulos de Young de hueso trabecular real con desviación del 0,040 % desde 16 pares iniciales, señalando que las ambigüedades rotacionales no impiden la convergencia, sin estudiarlas. He y Ren [7] demuestran el carácter uno-a-muchos del problema y lo sortean con inferencia bayesiana en el latente de un autoencoder variacional ($R^2 > 96\%$ multipropiedad). A mayor escala, TEGNet [4] emula generadores termoeléctricos con precisión mayor al 99 % en el 0,01 % del tiempo de elementos finitos.

En síntesis, los trabajos previos resuelven el diseño in-

verso con muy pocos datos, pero tratan la no-unicidad como un obstáculo: Raßloff *et al.* la mencionan sin medirla y He y Ren la ilustran sin caracterizarla. Ninguno estudia empíricamente su estructura: si es discreta o continua, qué dimensión tiene y de qué representación depende. Ese es el vacío que este trabajo aborda, mediante una comparación controlada de tres subrogados en régimen de datos limitados, un tratamiento completo de la incertidumbre y una caracterización empírica de la degeneración con tres herramientas complementarias, replicada sobre múltiples muestras y verificada ante variaciones del umbral.

5 METODOLOGÍA E IMPLEMENTACIÓN

5.1 Datos

El conjunto se generó con la ecuación de campo aleatorio gaussiano anisótropo de [1], muestreando uniformemente $\beta \in [5\pi, 15\pi]$, $\rho \in [0,3, 0,7]$ y $\theta_i \in [0^\circ, 89,9^\circ]$. De cada isosuperficie mallada con *pygalmesh* se extrajeron siete descriptores: área interna, externa y total, volumen, relación SA/V, porosidad y tamaño de poro. El dataset final tiene 10,011 muestras (8,008 train, 2,003 test, partición 80/20 con semilla fija). Los estadísticos de normalización se ajustan solo con el train para evitar fuga de información.

5.2 Modelos del mapeo directo

f-NN: MLP [512, 256, 256, 128], ReLU, dropout 0,1, salida lineal de dimensión 7; MSE, Adam (5×10^{-4} , *weight decay* 10^{-5}), *batch* 64, recorte de gradiente y *early stopping* (paciencia 25). **f-NN-prob:** mismo cuerpo con dos cabezas (μ_j y s_j , 14 salidas), entrenada con la Ecuación (1) y los mismos hiperparámetros, de modo que la comparación aísla el efecto de la función de pérdida. **GP:** un regresor independiente por propiedad (núcleo C · RBF + White con longitudes por dimensión, optimizado por verosimilitud marginal), entrenado con 2,240 muestras (28 %), el máximo que mantiene el entrenamiento de los siete regresores en tiempos razonables dado su costo $O(n^3)$.

Las arquitecturas e hiperparámetros se fijaron a partir de valores estándar y se mantuvieron constantes entre modelos: el objetivo es comparar funciones de pérdida y familias de modelo en igualdad de capacidad, no maximizar el rendimiento absoluto mediante búsqueda de hiperparámetros.

5.3 Modelos del mapeo inverso

i-NN: MLP [128, 128, 64], ReLU, dropout 0,1, salida de dimensión 5; pérdida de reconstrucción (7) con la f-NN congelada y cronograma $\lambda = 0,1$ en las primeras 20 épocas y 0 después; Adam (10^{-3}), paciencia 30. **Ensamble:** $M = 10$ i-NN con semillas distintas; la dispersión de $\{\hat{\Theta}_m\}$ es una aproximación discreta al conjunto de soluciones ($M = 10$ equilibra el costo de entrenamiento con la suficiencia estadística para

estimar una dispersión). **MDN:** mismo cuerpo que la i-NN y tres cabezas (π_k, μ_k, s_k); el sesgo de la cabeza de medias se inicializa uniforme en $[-1,5, 1,5]$ para evitar el colapso de componentes; NLL de mezcla (6) con $s_k \in [-7, 2]$, Adam (10^{-3}), *early stopping* (paciencia 30) sobre un split interno de validación del 10 % del train. Se entrenan dos versiones con arquitectura y protocolo idénticos: $K = 3$, el mínimo número de componentes capaz de expresar multimodalidad no trivial sin fragmentar la densidad, y el *baseline* unimodal $K = 1$, que aísla el efecto de la mezcla.

5.4 Experimentos

Curva de aprendizaje: f-NN con el 5, 10, 25, 50 y 100 % del train, cinco semillas por fracción. **Incertidumbre:** calibración por quintiles y ECE para f-NN-prob y GP; recalibración por *temperature scaling* (Ecuación (4)); cobertura empírica de intervalos (PICP, *Prediction Interval Coverage Probability*) y ancho medio (MPIW, *Mean Prediction Interval Width*) a niveles nominales del 68 y 95 %; barrido de β y ρ fuera del rango de entrenamiento para observar la incertidumbre declarada en extrapolación. **Importancia de variables:** permutación sobre la f-NN (diez repeticiones por parámetro, caída de R^2) y ARD del GP. **Kernels:** RBF frente a Matérn ($\nu = 2,5$) sobre la propiedad más fácil y la más difícil, comparados por log-verosimilitud marginal (LML) y R^2 . **Sesgo-varianza:** Ecuación (2) sobre cinco f-NN (directo) y los diez miembros del ensamble (inverso). **No-unicidad:** barrido Monte Carlo de 10^4 valores de Θ uniformes, filtrados por $\text{MSE}(\hat{G}, G^*) < \epsilon = 0,5$ vía la f-NN; el umbral central corresponde a medio desvío cuadrático en el espacio normalizado de G , y su posible arbitrariedad se controla replicando el protocolo sobre cinco muestras de test y con $\epsilon \in \{0,3, 0,5, 0,7\}$. El diagnóstico se triangula con tres vías (Monte Carlo, dispersión del ensamble y muestras de la MDN), comparando sus dispersiones angulares contra la uniforme teórica; la estructura de la degeneración se evalúa contrastando $K = 3$ frente a $K = 1$ en NLL, R^2 por modo dominante y varianzas por componente, y toda solución propuesta se valida por reconstrucción de G^* a través del mapeo directo. **Costo:** tiempo de inferencia por muestra de cada subrogado directo frente a la simulación física.

6 RESULTADOS

6.1 Mapeo directo y eficiencia de datos

La Tabla 1 resume el mapeo directo y la Figura 1 lo desglosa por propiedad. La f-NN-prob no pierde precisión al pasar de MSE a verosimilitud explícita, y el GP obtiene el mejor promedio usando el 28 % de los datos: domina en las propiedades suaves (área interna: 0,9992) y solo cede en tamaño de poro (0,9448), donde su desviación posterior promedio (0,242, nueve veces la de área interna) declara la dificultad de forma explícita.

Tabla 1: Métricas globales en test ($n = 2003$), mapeo directo.

Modelo	R^2	NLL	n_{train}
f-NN	0,9853	—	8,008
f-NN-prob	0,9871	-2,1065	8,008
GP	0,9887	—	2,240




Figura 1: R^2 por propiedad: GP (2,240 muestras) frente a f-NN (8,008).

La comparación de kernels (Tabla 2) muestra que Matérn ($\nu = 2,5$) supera a RBF en ambas propiedades evaluadas, con la ventaja más marcada en tamaño de poro: el supuesto de suavidad infinita del RBF es demasiado rígido para la propiedad con mayor estructura fina.

Tabla 2: Kernels del GP: log-verosimilitud marginal y R^2 en test. Matérn domina en LML, lo que lo sugiere como elección por defecto en trabajos futuros.

Propiedad	Kernel	LML	R^2
Área interna	RBF	4645,3	0,9991
Área interna	Matérn 2.5	4719,9	0,9992
Tamaño poro	RBF	-236,2	0,9364
Tamaño poro	Matérn 2.5	-180,7	0,9472

La curva de aprendizaje (Tabla 3) muestra que con 400 muestras la f-NN ya alcanza $R^2 = 0,9778$, el 99,0 % de su rendimiento final, con desviaciones entre semillas del orden de 10^{-3} .

En cuanto al costo de inferencia, frente a la simulación física (133,3 s por muestra), la f-NN predice en $3,0 \mu\text{s}$, un factor de $4,4 \times 10^7$; la f-NN-prob en $4,8 \mu\text{s}$ y el GP en $0,31 \text{ ms}$ ($4,3 \times 10^5$). El barrido Monte Carlo de 10^4 evaluaciones que sustenta el diagnóstico de la Sección 5.5 habría requerido unos 15 días de simulación y toma 0,03 s con el subrogado.

6.2 Importancia de variables

La Tabla 4 compara dos métodos independientes. La permutación sobre la f-NN es categórica: ρ (0,613) y β (0,383)

Tabla 3: Curva de aprendizaje de la f-NN (cinco semillas por fracción). Con el 5 % de los datos se alcanza el 99 % del rendimiento final.

Frac.	n_{train}	R^2 medio	Std
5 %	400	0,9778	0,0009
10 %	800	0,9816	0,0008
25 %	2002	0,9848	0,0004
50 %	4004	0,9861	0,0006
100 %	8008	0,9876	0,0008

concentran el 99,5 % de la importancia, mientras los tres ángulos suman menos del 0,5 %. El ARD del GP coincide en el orden de magnitud del contraste, con β (0,371) y ρ (0,336) dominando y los ángulos reducidos a 0,143, 0,100 y 0,051. La discrepancia entre ambos métodos en la magnitud angular es esperable: el ARD mide sensibilidad local del kernel, mientras la permutación mide impacto sobre el error global.

Tabla 4: Importancia relativa de los parámetros de diseño (normalizada). β y ρ concentran la influencia sobre G ; los ángulos son casi irrelevantes.

Parámetro	Permutación (f-NN)	ARD (GP)
β	0,383	0,371
ρ	0,613	0,336
θ_x	0,003	0,143
θ_y	0,001	0,100
θ_z	0,001	0,051

6.3 Calibración, recalibración y cobertura

Ambos modelos probabilísticos están razonablemente calibrados, pero fallan de maneras opuestas: la red es conservadora de forma sistemática, mientras el GP es preciso en promedio pero poco discriminativo. Los cinco quintiles de la f-NN-prob caen bajo la diagonal (cocientes $\text{MSE}/\mathbb{E}[\sigma^2]$ entre 0,50 y 0,78): el modelo sobreestima sistemáticamente su incertidumbre, con un ECE de $5,7 \times 10^{-3}$ (Tabla 5). El GP obtiene la mejor calibración absoluta (ECE = $2,8 \times 10^{-3}$, Figura 2) pero con un perfil distinto: declara varianzas casi homogéneas ($\mathbb{E}[\sigma^2]$ entre 0,0105 y 0,0130) y se vuelve *sobreconfiado* en los dos quintiles superiores (cocientes 1,37 y 1,19: el error real supera lo declarado). La f-NN-prob, en cambio, discrimina un rango de varianzas nueve veces mayor (0,0059 a 0,0522), es decir, ordena mucho mejor los casos por dificultad aunque su escala absoluta esté desplazada.

El *temperature scaling* corrige el sesgo de escala de la red. El factor óptimo de la Ecuación (4) resulta $s^* = 0,425$, coherente con los cocientes observados: la varianza declarada debe reducirse a menos de la mitad. Tras la corrección, el ECE

Tabla 5: Calibración por quintiles de σ^2 predicho. Cocientes < 1 indican sobreestimación de la incertidumbre; > 1 , subestimación.

Modelo	Q1	Q2	Q3	Q4	Q5
<i>Cociente</i> $\text{MSE}/\mathbb{E}[\sigma^2]$					
f-NN-prob	0,61	0,56	0,50	0,60	0,78
GP	0,79	0,73	0,79	1,37	1,19




Figura 2: Calibración comparada: GP (rojo) y f-NN-prob (azul). El GP se concentra cerca de la diagonal en un rango estrecho de varianzas; la f-NN-prob cubre un rango amplio pero sistemáticamente bajo la diagonal.

baja de $5,74 \times 10^{-3}$ a $4,84 \times 10^{-3}$ y la NLL en test mejora de $-8,313$ a $-8,822$, con la media (y por tanto el R^2) inalterada.

El efecto es mucho más visible en la cobertura de intervalos (Tabla 6). La f-NN-prob cruda sobre-cubre severamente: declara un intervalo del 68 % y captura el 84,2 % de los valores reales, y al 95 % nominal captura el 98,9 %, con intervalos innecesariamente anchos. Tras la recalibración la cobertura al 68 % cae a 65,8 %, casi exactamente nominal, con intervalos un 35 % más angostos. El GP entrega la mejor cobertura al 95 % (94,3 % frente al 92,2 % de la red calibrada).

6.4 Extrapolación fuera del dominio

El comportamiento fuera del rango de entrenamiento separa a los dos modelos probabilísticos (Figura 3). Al barrer β más allá de su máximo entrenado, la desviación posterior del GP se multiplica por 3,47 (y por 2,75 al extrapolar en ρ): el modelo advierte que está fuera de su dominio de validez, tal

Tabla 6: Cobertura empírica (PICP) y ancho medio (MPIW) de los intervalos de predicción.

Modelo	Nominal 68 %		Nominal 95 %	
	PICP	MPIW	PICP	MPIW
f-NN-prob cruda	0,842	0,212	0,989	0,415
f-NN-prob calibrada	0,658	0,138	0,922	0,270
GP	0,739	0,162	0,943	0,317

como predice la Ecuación (3). La f-NN-prob hace lo contrario: su σ declarado *disminuye* en extrapolación (factores 0,75 en β y 0,84 en ρ), es decir, se vuelve más confiada justamente donde no tiene información. La verosimilitud heterocedástica solo garantiza incertidumbre honesta dentro del soporte de los datos de entrenamiento; fuera de él, la red extrapola su cabeza de varianza sin ningún mecanismo que la obligue a crecer.




Figura 3: Incertidumbre declarada dentro y fuera del dominio de entrenamiento (zona sombreada). El GP infla su varianza al extrapolar; la f-NN-prob la reduce.

6.5 Mapeo inverso y no-unicidad

La i-NN reconstruye G con $R^2 \approx 0,99$ pero exhibe $R^2 < 0$ en los tres ángulos, consistente con el colapso al promedio de la Sección 2.5. El barrido Monte Carlo lo confirma: 2,217 de 10^4 muestras (22,17 %) reproducen G^* dentro de la tolerancia (Tabla 7, Figura 4). La desviación angular de $\approx 26^\circ$ coincide con la de una uniforme en $[0^\circ, 90^\circ]$ ($90/\sqrt{12} = 25,98^\circ$): dada G , los ángulos están esencialmente sin restringir, mientras β y ρ quedan acotados.

Tabla 7: Θ compatibles con G^* vía Monte Carlo (muestra #0, $n = 2217$). La desviación angular replica la de una uniforme.

Parám.	Media	Std	Mín	Máx
β	34,16	5,38	23,74	44,91
ρ	0,526	0,055	0,402	0,641
θ_x	43,77	26,24	0,01	89,89
θ_y	45,26	25,99	0,01	89,83
θ_z	44,41	25,96	0,01	89,82




Figura 4: Θ compatibles con G^* por barrido Monte Carlo; la línea roja marca el Θ verdadero.

El ensamble de 10 i-NN recupera β (33,8 a 34,2 frente al valor real 33,69) y ρ (0,505 a 0,512 frente a 0,517) con precisión, pero propone ángulos dispersos y alejados del Θ generador (60,2, 20,5, 50,5)°. La validación es contundente: cada miembro reproduce G^* con un error promedio de $8,2 \times 10^{-4}$, tres órdenes de magnitud bajo el umbral de compatibilidad.

6.6 Generalización y robustez del diagnóstico

El protocolo completo se replicó sobre cinco muestras de test (Tabla 8, Figura 5). El patrón es consistente: la fracción compatible varía entre el 15,7 y el 22,2 %, la dispersión angular Monte Carlo se mantiene en 25,6 a 26,1° y la MDN la replica (24,8 a 26,5°) en las cinco muestras. La dispersión del ensamble, en cambio, oscila entre 5,5 y 17,1°: subestima la incertidumbre real por un factor de dos a cinco y es además inestable entre muestras, evidencia de que sus miembros muestrean atractores del paisaje de optimización y no la condicional. El 100 % de las muestras extraídas de la MDN son físicamente válidas en los cinco casos.

Tabla 8: Diagnóstico replicado en cinco muestras. Dispersión angular promedio en grados (uniforme teórica: 25,98) y error de reconstrucción del ensamble.

#	Frac. MC	Std MC	Std MDN	Std ens.	Rec. ens.
0	22,2 %	26,1	25,9	6,5	0,0008
1	17,1 %	26,0	26,5	17,1	0,0077
2	15,7 %	25,6	24,8	6,9	0,0037
3	21,3 %	26,1	25,8	5,5	0,0009
4	17,4 %	25,9	26,2	14,4	0,0086

El diagnóstico es además robusto ante el umbral de compatibilidad (Tabla 9): al variar ϵ entre 0,3 y 0,7 la fracción compatible escala del 11,7 al 24,4 % y la dispersión de β crece de 4,33 a 6,43, como corresponde a un criterio más laxo, pero la dispersión angular permanece invariante en 25,9° en los tres umbrales. La degeneración angular no es un artefacto del




Figura 5: Generalización del diagnóstico: fracción compatible (izq.), dispersión angular Monte Carlo frente a MDN contra la uniforme teórica (centro) y validez física de las soluciones (der., escala logarítmica).

ϵ elegido.

Tabla 9: Sensibilidad al umbral ϵ (promedio sobre las cinco muestras). La dispersión angular es invariante.

ϵ	Frac. comp.	Std ang.	Std β
0,3	11,7 $\pm$ 1,5 %	25,92	4,33
0,5	18,7 $\pm$ 2,5 %	25,95	5,55
0,7	24,4 $\pm$ 4,4 %	25,96	6,43

6.7 Descomposición sesgo-varianza

El contraste central de la Tabla 10 está en la escala: el error inverso en los ángulos (4,4 a 8,6) es dos a tres órdenes de magnitud mayor que el directo (0,002 a 0,049), la firma cuantitativa del mal condicionamiento. El sesgo² domina en los tres ángulos, pero ese “sesgo” no mide un error del modelo sino la distancia entre la solución a la que converge el ensamble y la solución generadora, ambas válidas.

Tabla 10: Sesgo-varianza (espacio normalizado): directo (5 semillas) e inverso (ensamble de 10). Nótese la diferencia de escala de dos a tres órdenes de magnitud entre mapeos.

Dimensión	Sesgo ²	Varianza	Error
<i>Mapeo directo (f-NN)</i>			
Área interna	0,0014	0,0010	0,0024
Área externa	0,0203	0,0013	0,0215
Área total	0,0020	0,0011	0,0031
Volumen	0,0040	0,0012	0,0051
SA/V	0,0029	0,0012	0,0042
Porosidad	0,0040	0,0012	0,0052
Tamaño poro	0,0444	0,0049	0,0492
<i>Mapeo inverso (ensamble i-NN)</i>			
β	0,011	0,002	0,013
ρ	0,034	0,004	0,038
θ_x	4,322	0,102	4,424
θ_y	4,333	0,896	5,228
θ_z	7,974	0,585	8,559

6.8 Redes de densidad mixta: $K = 3$ frente al baseline $K = 1$

La MDN con $K = 3$ alcanza $NLL = 1,779$ en test con uso activo de las tres componentes ($\bar{\pi} = 0,23/0,52/0,25$), sin colapso. Su R^2 puntual con el modo dominante separa automáticamente los parámetros identificables de los degenerados: β alcanza 0,997 y ρ 0,993, mientras los tres ángulos quedan en $R^2 \approx 0$ (+0,011, -0,016, +0,008).

El baseline $K = 1$, con arquitectura y protocolo idénticos, obtiene $NLL = 1,933$: la mezcla mejora la verosimilitud en $\Delta = 0,154$. Sin embargo, el análisis de las varianzas del propio $K = 1$ revela dónde *no* está esa ganancia: sus desviaciones angulares promedio son 25,9, 26,5 y 26,2°, es decir, la gaussiana única se ensancha hasta reproducir la desviación de una uniforme, y su R^2 puntual en ángulos es igualmente nulo (+0,007, -0,001, +0,004) pese a recuperar β (0,999) y ρ (0,992). Consistentemente, los tres modos que la mezcla propone para la muestra de referencia difieren poco entre sí en los ángulos (θ_x : 45,2, 46,5, 45,6) y son componentes anchas y superpuestas antes que modos discretos separados (Figura 6). La mejora de la mezcla proviene de una mayor flexibilidad de forma de la densidad, no del descubrimiento de soluciones angulares discretas.




Figura 6: $p(\Theta | G^*)$ por tres vías: Monte Carlo (gris), muestras MDN (azul) y ensamble (naranja). Líneas navy: medias de las componentes (grosor $\propto \pi_k$); línea roja: Θ verdadero. En β y ρ la MDN concentra la masa; en los ángulos reproduce la dispersión casi uniforme.

Con esto, cuatro estimaciones independientes convergen al mismo valor de $\approx 26^\circ$ para la dispersión angular: el barrido Monte Carlo (26,1°), la mezcla $K = 3$ (25,9°), el baseline $K = 1$ (25,9 a 26,5°) y el cálculo teórico de la uniforme (25,98°). Dada G , los ángulos no contienen información recuperable, y los modelos de densidad lo declaran explícitamente mediante sus varianzas.

7 DISCUSIÓN

Subrogado directo y eficiencia de datos. Los tres modelos superan $R^2 = 0,985$, consistente con [1] y con la dirección

data-efficient de la literatura [3, 5]. Junto al *speedup* de siete órdenes de magnitud, el resultado práctico es que el cuello de botella del problema directo no es la cantidad de datos sino la representación elegida para G .

Incertidumbre: calibrar no es lo mismo que discriminar. El GP obtiene la mejor calibración absoluta (ECE = $2,8 \times 10^{-3}$), pero declara varianzas casi homogéneas y se vuelve sobreconfiado precisamente en los quintiles de mayor error. La f-NN-prob es sistemáticamente conservadora, aunque su varianza discrimina un rango nueve veces mayor, es decir, ordena mejor los casos por dificultad. Como el sesgo de la red es un factor de escala aproximadamente constante, el *temperature scaling* lo corrige casi por completo ($s^* = 0,425$): la cobertura al 68 % pasa de 84,2 % a 65,8 %, prácticamente nominal, con intervalos un tercio más angostos y sin tocar la media. Para aprendizaje activo, donde importa el orden de las incertidumbres, la red recalibrada es preferible; para intervalos al 95 %, el GP sigue siendo el más fiel.

Extrapolación: el GP sabe cuándo no sabe. El hallazgo de mayor relevancia práctica para el uso del subrogado es asimétrico: fuera del dominio de entrenamiento el GP multiplica su incertidumbre por 3,47 mientras la f-NN-prob la *reduce* a 0,75. Una red probabilística bien calibrada dentro del soporte puede ser peligrosamente confiada fuera de él, porque nada en la Ecuación (1) obliga a la cabeza de varianza a crecer donde no hay datos. En un flujo de diseño que explore regiones nuevas del espacio, el GP es el único de los tres modelos que emite una advertencia.

Del mapeo directo a la degeneración inversa. Dos métodos independientes coinciden en que β y ρ concentran casi toda la influencia sobre G y los ángulos son prácticamente irrelevantes. Si G apenas cambia al variar los ángulos, entonces G no puede identificarlos: la degeneración inversa es la imagen especular de la insensibilidad directa. Esto tiene además una explicación física, ya que los descriptores utilizados (áreas, volumen, porosidad) son escalares e invariantes ante reorientaciones de la microestructura.

Reinterpretación del sesgo. El R^2 negativo de la i-NN es la consecuencia de minimizar MSE sobre una condicional degenerada. La descomposición sesgo-varianza lo confirma en escala (dos a tres órdenes entre mapeos) pero su lectura clásica se invierte: el sesgo² alto mide la distancia entre soluciones válidas, no un error, como demuestra el error de reconstrucción de $8,2 \times 10^{-4}$.

Límites del ensamble. El análisis multi-muestra añade una limitación del ensamble como cuantificador de incertidumbre: su dispersión angular ($5,5$ a $17,1^\circ$) subestima la real (26°) y varía erráticamente entre muestras, porque sus miembros

exploran atractores del optimizador y no la distribución condicional. Evaluar con R^2 , con sesgo o con la dispersión de un ensamble llevaría a conclusiones erróneas; la evaluación correcta exige validar físicamente las soluciones a través del mapeo directo y estimar la condicional con un modelo de densidad.

Estructura de la degeneración. La mezcla $K = 3$ mejora la verosimilitud sobre el baseline unimodal ($\Delta = 0,154$), lo que confirma que la condicional tiene estructura que una sola gaussiana no captura. Pero esa estructura no está en los ángulos: el $K = 1$ aprende por sí solo desviaciones angulares indistinguibles de una uniforme, sus R^2 angulares son nulos igual que los del $K = 3$, y las tres componentes de la mezcla resultan anchas y superpuestas en las dimensiones angulares en lugar de separarse en modos. La degeneración angular es, por tanto, continua, no un conjunto discreto de soluciones. En el lenguaje de los problemas inversos corresponde a un núcleo no trivial de dimensión tres, análogo al que aparece en inversión geofísica con cobertura de datos insuficiente [10]. La no identificabilidad es una propiedad de la representación de G , no del modelo, y solo puede romperse enriqueciendo G con descriptores direccionales.

Limitaciones. Primero, toda la evidencia proviene de un único conjunto de datos sintético y la validación del mapeo inverso se realiza a través del propio subrogado, lo que introduce una circularidad parcial: un error sistemático de la f-NN sesgaría el diagnóstico. El riesgo está mitigado porque el subrogado se valida contra un test independiente con $R^2 > 0,985$, pero solo se elimina simulando físicamente las soluciones propuestas. Segundo, la comparación entre GP y redes no es simétrica ni en datos (2,240 frente a 8,008) ni en costo de entrenamiento: el GP requiere decenas de minutos para los siete regresores y escala $O(n^3)$, mientras cada MLP entrena en minutos y el ensamble multiplica ese costo por M ; la elección del modelo depende también de ese presupuesto, no solo de las métricas de test. Tercero, la cobertura experimental está acotada por costo computacional: los hiperparámetros se fijaron sin búsqueda (decisión deliberada para aislar el efecto de la función de pérdida, pero que implica que ninguna cifra reportada es necesariamente óptima para su familia de modelo), la curva de aprendizaje cubrió solo la f-NN y la comparación de kernels dos propiedades representativas. Cuarto, las diferencias pequeñas entre modelos ($\Delta R^2 \approx 0,003$) deben leerse contra la variabilidad entre semillas (del orden de 10^{-3} en la curva de aprendizaje): la ventaja del GP supera ese ruido, pero es modesta. Quinto, los descriptores escalares son una elección heredada del pipeline de mallado, y la degeneración caracterizada es relativa a esa representación; esta dependencia es a la vez la limitación y el hallazgo central del trabajo.

Trabajo futuro. Como extensiones: (i) contrastar la mezcla paramétrica con modelos generativos implícitos (autoencoders

variacionales condicionales, difusión) que muestreen configuraciones desde un espacio latente, siguiendo la comparación sistemática de [12]; (ii) incorporar descriptores direccionales (campos de orientación, tensores de anisotropía) para romper la degeneración desde la representación; (iii) validar las soluciones alternativas propuestas por la MDN generando las geometrías con el simulador.

8 CONCLUSIÓN

Se construyó un marco de modelos subrogados para el diseño inverso de metamateriales spinodoidales bajo restricciones de datos. En el mapeo directo los tres modelos superan $R^2 = 0,985$, con el GP liderando en precisión y calibración con una fracción de los datos, y con un *speedup* de siete órdenes de magnitud que hace viable el diagnóstico posterior. El tratamiento de la incertidumbre muestra que calibración y poder discriminativo son propiedades distintas, que un *temperature scaling* de solución cerrada lleva la cobertura de la red a valores casi nominales, y que solo el GP advierte cuándo se abandona el dominio de validez. En el mapeo inverso, la importancia de variables establece la causa (los ángulos apenas influyen sobre G) y el diagnóstico establece la consecuencia: una degeneración angular continua con dispersión de 26° , confirmada por cuatro estimaciones independientes e invariante ante el umbral de compatibilidad. La conclusión metodológica es que, en problemas inversos degenerados, las métricas puntuales, la descomposición sesgo-varianza clásica y la dispersión de un ensamble pierden su interpretación habitual: la evaluación correcta requiere modelar la distribución condicional completa y validar físicamente sus muestras a través del mapeo directo.

9 Video

<https://youtu.be/7qUofeM8SuQ>

Referencias

- [1] S. Kumar, S. Tan, L. Zheng y D. M. Kochmann, “Inverse-designed spinodoid metamaterials,” *npj Computational Materials*, vol. 6, art. 73, 2020.
- [2] C. M. Bishop, “Mixture density networks,” Technical Report NCRG/94/004, Aston University, 1994.
- [3] M. Rosenkranz, M. Kästner e I. F. Sbalzarini, “Data-efficient inverse design of spinodoid metamaterials,” *Integrating Materials and Manufacturing Innovation*, vol. 14, pp. 695–713, 2025.
- [4] A. Li *et al.*, “Composable neural emulators accelerate thermoelectric generator design,” *Nature*, vol. 652, pp. 643–649, 2026.
- [5] H. Danesh, M. Annamaraju, T. Brepols, S. Reese y S. R. Kalidindi, “Reduced-order structure-property linkages for stochastic metamaterials,” *arXiv:2505.01283*, 2025.
- [6] H. Danesh y H. Wessels, “Bayesian-guided inverse design of hyperelastic microstructures: Application to stochastic metamaterials,” *arXiv:2603.15917*, 2026.
- [7] L. He y X. Ren, “Inverse design of stochastic metamaterials via multi-physical knowledge fusion driven by deep-generative-prior Bayesian inference,” *Computers & Structures*, vol. 325, art. 108162, 2026.
- [8] A. Raßloff, P. Seibert, K. A. Kalina y M. Kästner, “Inverse design of spinodoid structures using Bayesian optimization,” *Computational Mechanics*, vol. 77, pp. 275–296, 2026.
- [9] M. Haltmeier y L. Nguyen, “Regularization of inverse problems by neural networks,” *arXiv:2006.03972*, 2020.
- [10] C. L. Mills, M. L. Rudolph y V. Lekić, “Exploring and summarizing ensemble solutions to geophysical inverse problems,” *Journal of Geophysical Research: Machine Learning and Computation*, vol. 2, e2024JH000472, 2025.
- [11] Z. Tan, Y. Hao, B. Zou, M. Long, Y. Yang y G. Bao, “Harnessing AI for inverse partial differential equation problems: Past, present, and prospects,” *arXiv:2605.16966*, 2026.
- [12] L. F. Guilhoto, A. Kaushal y P. Perdikaris, “Multimodal scientific learning beyond diffusions and flows,” *arXiv:2602.00960*, 2026.